INSTITUTO TECNOLÓGICO DE ESTUDIOS SUPERIORES DE MONTERREY



ESCUELA DE INGENIERÍA Y CIENCIAS
Campus Querétaro (QRO)

Inteligencia artificial avanzada para la ciencia de datos

TC3009C.601

Data Understanding

Data Description Report

Profesor:

Eduardo Daniel Juárez Pineda

Miembros de equipo:

Jacob Espejel Guiza
A0171204321

Sebastian Osorio Arteaga
A01706119

Ximena Pérez Escalante
A01751827

Aron Cortez Villafuerte
A01666725

Jose Eduardo Perez Abundiz
A01666860

Querétaro, 21 de octubre 2026

1. Objetivo del reporte

2. Panorama de los datos

3. Conjunto propio de CAETEC

4. Conjunto de Huang

5. Conjunto de Zenodo

6. Estructura de variables

7. Adecuación a las necesidades del proyecto

8. Conclusión

Referencias

1. Objetivo del reporte

Este documento describe la estructura, el volumen y las características de las nuevas fotografías de vacas Holstein de CAETEC y de las calificaciones BCS recibidas. CAETEC es el dataset principal para desarrollar y comparar dos clasificadores: uno con imágenes completas y otro con la vaca o región de interés localizada mediante Roboflow. El dataset Huang se conserva como fuente externa secundaria para una evaluación posterior. Los problemas de integridad y consistencia se desarrollan por separado en el Data Quality Report.

2. Panorama de los datos

Conjunto	**Unidad registrada**	**Volumen útil**	**BCS**	**Vista y sensor**
CAETEC	Fotografía	Se reportan 404 fotografías nuevas. La hoja calificada contiene 83 registros correspondientes a 69 animales; su correspondencia exacta todavía debe reconciliarse.	Escala 1–5, con siete valores observados de 2.25 a 3.75 en incrementos de 0.25.	iPhone. Captura manual en el entorno objetivo.

Conjunto	Unidad registrada	Volumen útil	BCS	Vista y sensor
Huang	Imagen con XML	53,566 imágenes y 53,566 anotaciones.	3.25, 3.50, 3.75, 4.00 y 4.25.	GS cenital. L y R diagonales.
Zenodo	Par RGB–profundidad	25,700 pares etiquetados de 1,025 animales.	2.75 a 5.00 en incrementos de 0.25.	Kinect cenital fijo a 3.05 m en sala rotatoria.
Dryad	Video RGB-De imagen DGE	5,940 imágenes DGE y 156 archivos bag.	Escala 1–9.	Intel RealSense D435 sobre ganado Criollo.

3. Conjunto propio de CAETEC

Las nuevas fotografías de CAETEC representan el dominio principal del proyecto y reemplazan la colección anterior para el experimento actual. Se reportan 404 fotografías, mientras que la hoja calificada contiene 83 registros asociados con 69 animales. Estas cantidades describen unidades diferentes y todavía debe verificarse cuántas fotografías corresponden a cada registro, cuáles son utilizables y qué vista o región anatómica muestran.

La copia calificada incluye Cow ID, referencias de carpeta y archivo y un BCS para sus 83 registros. La escala observada comprende 2.25, 2.50, 2.75, 3.00, 3.25, 3.50 y 3.75, con frecuencias de 1, 15, 13, 21, 16, 10 y 7 registros, respectivamente. El Cow ID debe utilizarse para agrupar las particiones y no como predictor. La procedencia detallada de las etiquetas —número de veterinarios, fecha y posible consenso— aún debe confirmarse.

La caracterización visual de la colección nueva se completará con las fotografías vigentes; la imagen de ejemplo de la colección anterior fue retirada para evitar confundir ambas recopilaciones.

4. Conjunto de Huang

Huang et al. publican un conjunto de gran escala para estimación de BCS en ganado lechero. Cada imagen JPG tiene un XML en formato Pascal VOC. Los XML contienen nombre del archivo, dimensiones, clase y una caja delimitadora. La inspección local mostró imágenes de 1,920 × 1,080 píxeles y cinco clases de BCS entre 3.25 y 4.25. Este análisis se conserva, pero Huang queda como dataset externo secundario y no participará en la comparación inicial de CAETEC.

Los nombres de archivo permiten identificar la mayoría de las vacas y la cámara. Se recuperaron 5,403 identificadores distinguibles. Otros 8,972 archivos de cámaras L o R utilizan un patrón que no permite relacionar la imagen con una vaca específica. La cámara GS incluye además una marca temporal. Estas variables son útiles para construir grupos y detectar información contextual que no debería sustituir la morfología del animal.

5. Conjunto de Zenodo

El conjunto de Ruchay et al. contiene capturas sincronizadas RGB y profundidad de una sala de ordeño rotatoria. Dataset.xlsx contiene 25,700 registros, 1,025 animales, cuatro sesiones, el BCS, el número de frame y las rutas de ambos archivos. Cada paso del animal genera veinte frames, por lo que varios registros describen casi la misma escena. Se conserva como referencia complementaria y queda fuera del experimento inicial.

Los RGB inspeccionados son PNG de 1,920 × 1,080 con cuatro canales. Los mapas de profundidad son PNG de 512 × 424 y 16 bits. La página del repositorio los describe como imágenes normalizadas de 8 bits, pero los archivos locales

conservan profundidad en milímetros. RGB y profundidad no están alineados píxel a píxel y con frecuencia aparecen varias vacas en una misma escena.

6. Estructura de variables

Fuente	Campo o señal	Tipo	Interpretación para el proyecto
CAETEC	Cow ID	Categórico	Identifica al animal y define el grupo de partición.
CAETEC	BCS	Ordinal	Variable objetivo en escala de cinco puntos.
CAETEC	Imagen	RGB	Entrada correspondiente al dominio de despliegue.
Huang	class	Ordinal	BCS discreto entre 3.25 y 4.25.
Huang	camera / filename	Categórico	Vista, secuencia e identidad cuando el patrón lo permite.
Huang	bndbox	Coordenadas	Región de la vaca anotada en la imagen.
Zenodo	animal	Categórico	Identificador para agrupar registros por vaca.

Fuente	Campo o señal	Tipo	Interpretación para el proyecto
Zenodo	date	Temporal	Sesión de captura y posible cambio longitudinal.
Zenodo	frame	Entero	Posición dentro de una secuencia de veinte imágenes.
Zenodo	rgb / depth	Ruta	Par de archivos sincronizados.
Zenodo	bcs	Ordinal	Etiqueta de 2.75 a 5.00 en incrementos de 0.25.

7. Adecuación a las necesidades del proyecto

Necesidad	Cobertura disponible	Valoración
BCS en escala de cinco puntos	CAETEC, Huang y Zenodo usan una escala compatible. Dryad usa nueve puntos.	Adecuada en las tres fuentes principales.
Casos delgados del CAETEC	CAETEC presenta valores observados de 2.25 a 3.75. Zenodo comienza en 2.75 y Huang en 3.25.	Insuficiente en fuentes externas para cubrir el extremo inferior observado en CAETEC.

Necesidad	Cobertura disponible	Valoración
Vista posterior con teléfono	Solo CAETEC coincide plenamente. Huang y Zenodo usan cámaras fijas y vistas más altas.	Brecha importante de dominio.
Identidad por animal	CAETEC y Zenodo la incluyen. Huang la conserva parcialmente.	Suficiente si se filtran archivos ambiguos.
Anotación espacial	Huang contiene cajas delimitadoras. CAETEC todavía no cuenta con anotaciones espaciales validadas; se planea generarlas en Roboflow para el segundo clasificador.	El segundo modelo que tenemos pensado hacer requiere localizar o recortar la vaca o región de interés sin sustituir la etiqueta BCS.
Despliegue iOS	Las entradas externas son de mayor resolución o incluyen profundidad.	Debe definirse una canalización RGB compatible con iPhone.

8. Conclusión

Las nuevas fotografías de CAETEC constituyen el dataset principal: se reportan 404 imágenes y existen 83 registros calificados de 69 animales con BCS entre 2.25 y 3.75. Estos datos permiten preparar los dos clasificadores propuestos, pero primero deben reconciliarse las fotografías con el manifiesto, resolver duplicados y valores múltiples por animal y documentar la procedencia de las etiquetas. Huang conserva valor por su volumen y sus anotaciones espaciales, pero se evaluará únicamente después de comparar los dos enfoques con CAETEC. Zenodo y Dryad permanecen como referencias complementarias.

Referencias

Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. https://www.dataprix.com/files/CRISP-DM.pdf

IBM. Data Understanding overview, CRISP-DM for SPSS Modeler. https://www.ibm.com/docs/en/spss-modeler/saas?topic=understanding-data-overview

Huang, H. et al. (2025). Dairy cow body condition score dataset. China Scientific Data. https://doi.org/10.11922/11-6035.csd.2024.0126.zh

Science Data Bank. Dairy cow body condition score dataset. https://doi.org/10.57760/sciencedb.16704

Ruchay, A., Kolpakov, V. y Riazanov, V. (2026). RGB-D Image Dataset for Automated Body Condition Scoring of Dairy Cows in Rotary Milking Parlors. https://doi.org/10.5281/zenodo.20290988

Winkler, D. y Boucheron, L. (2023). Criollo cattle video and depth dataset. https://doi.org/10.5061/dryad.tqjq2bw4s