INSTITUTO TECNOLÓGICO DE ESTUDIOS SUPERIORES DE MONTERREY



ESCUELA DE INGENIERÍA Y CIENCIAS
Campus Querétaro (QRO)

Inteligencia artificial avanzada para la ciencia de datos

TC3009C.601

Data Understanding

Data Quality Report

Profesor:

Eduardo Daniel Juárez Pineda

Miembros de equipo:

Jacob Espejel Guiza
A0171204321

Sebastian Osorio Arteaga
A01706119

Ximena Pérez Escalante
A01751827

Aron Cortez Villafuerte
A01666725

Jose Eduardo Perez Abundiz
A01666860

Querétaro, 21 de octubre 2026

1. Objetivo del reporte

2. Alcance

3. Resultado general

4. Verificación por fuente y atributo

4.1. CAETEC

4.2. Conjuntos externos (uso diferido)

5. Problemas prioritarios y acciones recomendadas

6. Conclusión

1. Objetivo del reporte

Este reporte evalúa la calidad de los datos que se utilizarán en la fase inicial del proyecto para entrenar y comparar dos modelos de Body Condition Score (BCS) en vacas Holstein. El análisis se concentra en las nuevas fotografías de CAETEC, su relación con el identificador del animal y las calificaciones BCS recibidas. Se revisan completitud, validez, consistencia, unicidad, trazabilidad, distribución de clases y calidad potencial de las imágenes. Los conjuntos externos se mantienen fuera de la comparación inicial y se consideran únicamente como candidatos para una fase posterior.

2. Alcance

El alcance actual comprende las nuevas capturas de CAETEC. Las fotografías de la recopilación anterior quedan fuera de esta etapa. Se reportan 404 fotografías nuevas, mientras que la hoja calificada contiene 83 registros asociados con 69 animales; estos conteos representan unidades distintas y su correspondencia todavía debe reconciliarse. El análisis utiliza resultados agregados y no reproduce identificadores individuales.

3. Resultado general

El conjunto calificado contiene 83 registros y todos tienen un valor BCS numérico. Los registros corresponden a 69 animales identificados. La escala observada abarca de 2.25 a 3.75 en incrementos de 0.25. La disponibilidad de etiquetas permite preparar los dos clasificadores propuestos, pero el conjunto aún requiere controles de trazabilidad, unicidad y consistencia antes de considerarse listo para una evaluación reproducible.

La distribución por registro es: BCS 2.25 (1), 2.50 (15), 2.75 (13), 3.00 (21), 3.25 (16), 3.50 (10) y 3.75 (7). Existe desbalance, especialmente en los extremos. Además, siete animales presentan más de un BCS y la diferencia observada es de 0.25 puntos. Esto no demuestra por sí solo un error, pues podría corresponder a

variación de evaluación, captura o momento; sin metadatos adicionales debe tratarse como una inconsistencia pendiente de revisión.

4. Verificación por fuente y atributo

4.1. CAETEC

Identificador de vaca (Cow ID). Los 83 registros calificados incluyen un identificador y representan 69 animales únicos. El Cow ID es necesario para relacionar las fotografías con el BCS y para formar las particiones de entrenamiento, validación y prueba. Varias fotografías de un mismo animal no constituyen observaciones independientes y deben permanecer en una sola partición.

Acción: utilizar una llave compuesta por Cow ID, carpeta, archivo y registro de captura. No usar únicamente el nombre del archivo. Mantener juntas todas las imágenes del mismo animal y documentar cualquier registro cuya identidad o relación con la carpeta no pueda verificarse.

BCS recibido. Los 83 registros de la copia calificada contienen BCS entre 2.25 y 3.75, en incrementos válidos de 0.25. La completitud de esta columna es de 100 % en la copia calificada. Sin embargo, el manifiesto activo conserva vacía su columna BCS y la hoja no registra evaluador, fecha de evaluación, método, nivel de acuerdo ni estado de validación. Por ello, los valores se consideran etiquetas externas recibidas y no se describen todavía como consenso o ground truth definitivo.

Acción: definir cuál hoja será el manifiesto maestro y conservar los BCS sin sobrescribir su procedencia. Añadir, cuando la información esté disponible, fuente de la etiqueta, fecha, versión y estado de validación. Cualquier consolidación entre hojas debe hacerse mediante una llave verificada y no mediante el orden de las filas.

Cobertura de clases. Las siete clases observadas no están equilibradas. La clase 2.25 cuenta con un solo registro y la clase 3.75 con siete, mientras que las clases centrales concentran la mayoría de los datos. La ausencia de valores como 1.00,

2.00, 4.00 o 5.00 describe el rango observado y no debe registrarse como valor faltante.

Implicación: el desempeño solo podrá sostenerse para las clases con evidencia suficiente. La clase 2.25 no puede evaluarse de manera confiable como categoría independiente con una sola observación. La partición deberá preservar, en la medida de lo posible, la distribución por clase sin dividir fotografías del mismo animal.

Fotografías e información de captura. Se reportan 404 fotografías nuevas, pero la hoja calificada contiene 83 registros y una referencia de archivo por registro. Antes de calcular suficiencia o tasas de defecto debe establecerse cuántas fotografías corresponden a cada registro, cuántas son utilizables y si todas pertenecen a las nuevas capturas. La revisión visual de iluminación, nitidez, oclusión, encuadre y visibilidad anatómica todavía debe cuantificarse.

Hallazgos y acciones:

1. Conservar un manifiesto por fotografía con Cow ID, carpeta, archivo, vista, fecha de captura, BCS recibido y estado de uso. Registrar por separado imágenes completas, imágenes excluidas y futuras anotaciones de Roboflow. Aplicar reglas reproducibles para identificar desenfoque, sobreexposición, subexposición, oclusión y región anatómica insuficiente.
2. La nueva sesión de captura ya se realizó y reemplaza las fotografías anteriores para esta fase. Debe documentarse la relación entre las 404 fotografías reportadas, los 83 registros calificados y los 69 animales. Hasta completar esa reconciliación no debe afirmarse que todas las fotografías están etiquetadas o listas para entrenamiento.
3. Procedencia de las etiquetas. Las calificaciones fueron recibidas después de solicitar la participación de veterinarios externos, pero actualmente no se ha confirmado el número de evaluadores ni si los valores representan evaluaciones individuales o un consenso. Esta incertidumbre debe registrarse como metadato pendiente y no impide los controles técnicos iniciales de formato y asociación.

4. Estrategia experimental. El primer clasificador utilizará las imágenes completas. El segundo utilizará las mismas fotografías después de localizar o recortar la vaca o la región de interés mediante anotaciones en Roboflow. Roboflow aportará anotación espacial y no sustituirá la clase BCS. Ambos clasificadores deberán usar las mismas clases, los mismos animales de entrenamiento, validación y prueba y las mismas métricas.

Suficiencia, unicidad y consistencia. Los 83 registros no equivalen a 83 animales independientes. Se identificaron siete nombres de archivo repetidos; algunos aparecen vinculados con animales o valores BCS diferentes. También existen siete animales con dos BCS separados por 0.25. Los nombres repetidos pueden ser válidos cuando pertenecen a carpetas distintas, pero impiden usar el nombre del archivo como identificador global.

Acción: revisar los registros repetidos mediante la combinación Cow ID–carpeta–archivo, decidir el tratamiento de los animales con más de un BCS y generar una partición reproducible por animal. La evaluación debe informar resultados por registro y por animal, además de la distribución de clases en cada partición.

4.2. Conjuntos externos (uso diferido)

El conjunto Huang o dataset chino se conserva como la segunda fuente en la jerarquía del proyecto, después de las nuevas fotografías de CAETEC. El trabajo previo sigue siendo válido: contiene 53,566 imágenes JPG con 53,566 anotaciones Pascal VOC en XML, cinco clases BCS entre 3.25 y 4.25 y capturas de las cámaras GS, L y R. Las cajas delimitadoras pueden apoyar el enfoque con localización o recorte. No obstante, la distribución de clases cambia entre cámaras, parte de los archivos no permite recuperar con seguridad la identidad del animal y sus vistas, dispositivos y dominio difieren de CAETEC. Por estas razones no se utilizará en la comparación inicial.

Después de comparar los dos clasificadores de CAETEC, se evaluará el dataset Huang en la representación compatible con el enfoque ganador: imágenes completas si funciona mejor el primer clasificador, o imágenes anotadas o

recortadas si funciona mejor el segundo. Según los resultados podrá combinarse con el entrenamiento, utilizarse para preentrenamiento y ajuste posterior o excluirse.

Zenodo y Dryad no forman parte del experimento actual. Se conservan únicamente como referencias documentales y no deben mezclarse con las etiquetas de CAETEC sin una evaluación independiente de escala, población, vista, modalidad y unidad de observación.

5. Problemas prioritarios y acciones recomendadas

1. Reconciliar las unidades del conjunto propio. Documentar la relación entre 404 fotografías reportadas, 83 registros calificados y 69 animales, y cuantificar cuántas imágenes son utilizables para cada experimento.
2. Definir el manifiesto maestro. Integrar las etiquetas mediante una llave verificada, conservar la procedencia y evitar que el orden de las filas o el nombre aislado del archivo determinen la asociación.
3. Resolver duplicados y valores múltiples. Revisar los nombres de archivo repetidos y los siete animales con dos BCS separados por 0.25 antes de formar las particiones.
4. Evaluar calidad visual. Medir iluminación, contraste, nitidez, oclusión, encuadre, orientación y visibilidad de la región anatómica; registrar criterios de inclusión y exclusión por fotografía.
5. Controlar el desbalance de clases. Informar la distribución por registro y por animal, evitar conclusiones para clases con soporte insuficiente y usar métricas por clase además del resultado global.
6. Evitar la fuga de información. Separar entrenamiento, validación y prueba por Cow ID. Usar exactamente las mismas particiones y clases al comparar el clasificador de imágenes completas con el clasificador basado en anotaciones de Roboflow.
7. Posponer la incorporación de datos externos. Comparar primero los dos enfoques con CAETEC. Después de elegir el ganador, evaluar si Huang

puede combinarse con el entrenamiento, utilizarse para pre entrenamiento o excluirse. Zenodo y Dryad permanecen fuera del experimento actual.

6. Conclusión

Las nuevas capturas de CAETEC ya cuentan con un primer conjunto completo de calificaciones BCS en la hoja revisada: 83 registros, 69 animales y siete clases entre 2.25 y 3.75. Esto permite preparar los dos clasificadores propuestos. Sin embargo, la calidad del conjunto todavía no está acreditada para una evaluación final reproducible: deben reconciliarse las 404 fotografías reportadas con el manifiesto, resolver referencias repetidas y valores múltiples por animal, documentar la procedencia de las etiquetas, medir la calidad visual y establecer una partición por Cow ID. El dataset Huang no participará en la comparación inicial; su incorporación se decidirá únicamente después de identificar el enfoque ganador y comprobar compatibilidad de clases, vistas y anotaciones.