INSTITUTO TECNOLÓGICO DE ESTUDIOS SUPERIORES DE MONTERREY



ESCUELA DE INGENIERÍA Y CIENCIAS
Campus Querétaro (QRO)

Inteligencia artificial avanzada para la ciencia de datos

TC3009C.601

Data Understanding

Initial Data Collection Report

Profesor:

Eduardo Daniel Juárez Pineda

Miembros de equipo:

Jacob Espejel Guiza
A0171204321

Sebastian Osorio Arteaga
A01706119

Ximena Pérez Escalante
A01751827

Aron Cortez Villafuerte
A01666725

Jose Eduardo Perez Abundiz
A01666860

Querétaro, 21 de octubre 2026

1. Propósito y alcance

2. Fuentes recopiladas

3. Procedimiento de adquisición

3.1 Datos propios de CAETEC

3.2 Conjuntos externos

4. Incidencias de recopilación y respuesta

5. Estado de la recopilación

Referencias

Para la fase de Data Understanding, se sigue la metodología CRISP-DM en su forma original, sin ninguna adaptación.

1. Propósito y alcance

Este reporte documenta la obtención y consolidación inicial de los datos que sostienen el proyecto del equipo Vacones. La fuente principal está formada por las nuevas fotografías de vacas Holstein capturadas en CAETEC y por las calificaciones de Body Condition Score (BCS) recibidas posteriormente. El objetivo experimental inmediato es desarrollar y comparar dos clasificadores BCS: uno con imágenes completas y otro con la vaca o región de interés localizada mediante anotaciones en Roboflow.

La recopilación se organiza de manera jerárquica. Las nuevas fotografías de CAETEC constituyen el dataset principal porque representan el entorno de aplicación. El conjunto Huang o dataset chino se conserva como la fuente externa secundaria y podrá evaluarse después de comparar los dos clasificadores con CAETEC. Zenodo y Dryad permanecen como referencias complementarias y no forman parte del experimento inicial.

2. Fuentes recopiladas

Fuente	**Contenido reunido**	**Papel en el proyecto**
CAETEC	Se reportan 404 fotografías nuevas. La hoja calificada contiene 83 registros con BCS correspondientes a 69 animales; la relación exacta entre fotografías, registros y animales todavía debe reconciliarse.	Dataset principal: dominio objetivo para desarrollar y comparar los dos clasificadores BCS.
Huang et al. / ScienceDB	53,566 imágenes JPG y 53,566 anotaciones	Dataset externo secundario. Se conserva para una evaluación

	Pascal VOC en XML. Clases de 3.25 a 4.25.	posterior al comparar los dos clasificadores de CAETEC.
Ruchay et al. / Zenodo	25,700 pares RGB-profundidad descritos en Dataset.xlsx, correspondientes a 1,025 animales.	Referencia complementaria con identidad por animal, sesiones y un intervalo de BCS más amplio; fuera del experimento inicial.
Winkler y Boucheron / Dryad	5,940 imágenes DGE y 156 archivos de video RGB-D de ganado Criollo, con escala corporal de 1 a 9.	Fuente revisada y descartada como base principal por diferencias de especie productiva, escala y formato.

3. Procedimiento de adquisición

3.1 Datos propios de CAETEC

La colección vigente corresponde a nuevas fotografías capturadas en CAETEC y reemplaza la colección anterior para el experimento actual. Se reportan 404 fotografías nuevas. El archivo con calificaciones contiene 83 registros con BCS y 69 animales identificados.

Las calificaciones fueron recibidas después de solicitar apoyo a veterinarios externos. Cada fotografía está relacionada con Cow ID, carpeta, nombre de archivo, vista y BCS. La unidad independiente continúa siendo el animal, por lo que todas las fotografías de una misma vaca deberán permanecer en una sola carpeta.

3.2 Conjuntos externos

El conjunto de Huang se descargó desde Science Data Bank. La estructura recibida separa imágenes y archivos XML, con correspondencia uno a uno entre ambos tipos

de archivo. Los nombres codifican la clase de BCS, el identificador cuando está disponible, la cámara y un consecutivo. La cámara GS corresponde a una vista cenital, mientras que L y R corresponden a vistas diagonales laterales. Este trabajo se conserva, pero Huang no se utilizará hasta concluir la comparación inicial con CAETEC.

El conjunto de Zenodo se obtuvo en cinco archivos comprimidos y una hoja Dataset.xlsx. Las carpetas representan cuatro sesiones de captura. La sesión del 27 de marzo se distribuye en dos volúmenes. La hoja de cálculo proporciona animal, sesión, BCS, número de frame y rutas de los archivos RGB y de profundidad. Durante la revisión se comprobó que todas las rutas declaradas en la hoja existen.

El conjunto de Dryad se descargó y revisó como alternativa para aprendizaje de representaciones. Su población corresponde a ganado Criollo de carne y usa una escala de nueve puntos, por lo que no se integrará directamente con las etiquetas de cinco puntos del proyecto.

4. Incidencias de recopilación y respuesta

Incidencia	**Efecto**	**Tratamiento adoptado o pendiente**
Las 404 fotografías reportadas todavía no están reconciliadas con los 83 registros calificados y los 69 animales.	Impide afirmar que todas las fotografías nuevas tienen una etiqueta BCS verificada y que están listas para entrenamiento.	Consolidar un manifiesto por fotografía con Cow ID, carpeta, archivo, vista, BCS y estado de uso, conservando los originales.
El manifiesto activo mantiene vacía la columna BCS, mientras que una	Existe riesgo de asociar etiquetas por orden de fila o por nombre de archivo sin	Definir el manifiesto maestro e integrar las calificaciones mediante Cow ID, carpeta,

copia contiene las calificaciones recibidas.	una llave suficientemente verificada.	archivo y registro de captura, conservando la procedencia.
Zenodo distribuye una sesión en dos archivos y conserva frames no incluidos en Dataset.xlsx.	Un conteo directo de PNG no coincide con los 25,700 pares etiquetados.	Usar Dataset.xlsx como manifiesto de referencia y separar los 880 pares sin etiqueta.
La descripción de Zenodo indica profundidad normalizada a 8 bits, pero los archivos inspeccionados son PNG de 16 bits en milímetros.	Puede producir transformaciones incorrectas si se confía únicamente en la página del repositorio.	Leer el tipo y rango de los archivos antes de normalizar. Documentar la discrepancia.
La licencia del conjunto de Huang no está indicada de forma suficientemente visible en los archivos locales.	Existe incertidumbre para redistribuir imágenes o integrarlas en un producto.	Confirmar por escrito las condiciones de uso antes de una liberación externa.
El conjunto de Dryad no es directamente comparable con el dominio objetivo.	La mezcla de etiquetas introduciría ambigüedad biológica.	Mantenerlo fuera del entrenamiento supervisado principal y documentar cualquier uso auxiliar.

5. Estado de la recopilación

La recopilación actual permite continuar Data Understanding con CAETEC como dataset principal: existen nuevas fotografías y un primer conjunto completo de 83 registros calificados. Antes del modelado deben reconciliarse las 404 fotografías, los 83 registros y los 69 animales, revisar duplicados y documentar la procedencia de las etiquetas. El trabajo de Huang se conserva como segunda prioridad y su incorporación se decidirá después de comparar los dos clasificadores de CAETEC. Zenodo y Dryad permanecen como referencias complementarias.

Referencias

Chapman, P. et al. (2000). CRISP-DM 1.0: Step-by-step data mining guide. https://www.dataprix.com/files/CRISP-DM.pdf

IBM. Data Understanding overview, CRISP-DM for SPSS Modeler. https://www.ibm.com/docs/en/spss-modeler/saas?topic=understanding-data-overview

Huang, H. et al. (2025). Dairy cow body condition score dataset. China Scientific Data. https://doi.org/10.11922/11-6035.csd.2024.0126.zh

Science Data Bank. Dairy cow body condition score dataset. https://doi.org/10.57760/sciencedb.16704

Ruchay, A., Kolpakov, V. y Riazanov, V. (2026). RGB-D Image Dataset for Automated Body Condition Scoring of Dairy Cows in Rotary Milking Parlors. https://doi.org/10.5281/zenodo.20290988

Winkler, D. y Boucheron, L. (2023). Criollo cattle video and depth dataset. https://doi.org/10.5061/dryad.tqjq2bw4s