INSTITUTO TECNOLÓGICO DE ESTUDIOS SUPERIORES DE MONTERREY



ESCUELA DE INGENIERÍA Y CIENCIAS
Campus Querétaro (QRO)

Inteligencia artificial avanzada para la ciencia de datos

TC3009C.601

Big Data and Cloud computing

Arquitectura del proyecto

Profesor:

Ismael Solis Moreno

Miembros de equipo:

Jacob Espejel Guiza
A01712021

Sebastian Osorio Arteaga
A01706119

Ximena Pérez Escalante
A01751827

Aron Cortez Villafuerte
A01666725

Jose Eduardo Perez Abundiz
A01666860

Querétaro, 23 de octubre 2026

Herramientas **2**

Modelo de almacenamiento de datos **3**

Conjunto de datos **3**

Extracción el conjunto de datos, limpieza y carga a la plataforma seleccionada 3

Scripts de configuración 4

Muestra cargada al repositorio de Github 5

Separación de datos 5

Enfoque del proyecto (Big Data) **5**

Herramientas

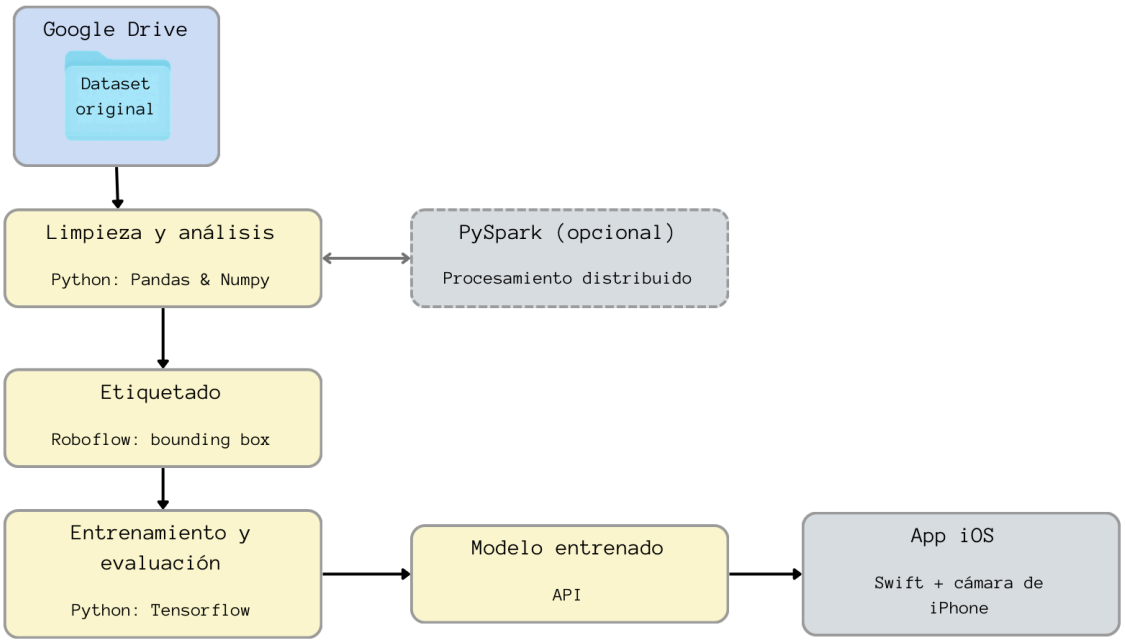
Las herramientas y tecnologías que se usarán para trabajar con los datos son:

1. **Python**
    a. Lenguaje principal para el procesamiento de datos y desarrollo del modelo de IA.
    b. Permite integrar fácilmente librerías de análisis y visión computacional.
2. **Pandas y NumPy**
    a. Para limpiar, organizar y analizar los datos de CAETEC, Huang y Zenodo.
    b. Nos permiten identificar valores faltantes, duplicados y analizar las distribuciones de BCS.
3. **TensorFlow**
    a. Para desarrollar y entrenar el modelo de visión computacional.
    b. Permitirá estimar el Body Condition Score (BCS) a partir de fotografías.
4. **PySpark (Apache Spark)**

    Su uso dependerá de si el volumen de datos justifica el procesamiento distribuido.

    a. Para explorar el procesamiento paralelo de grandes cantidades de datos.
    b. Puede facilitar la integración y transformación de los diferentes datasets.
5. **Swift (iOS)**
    a. Para desarrollar la aplicación móvil.
    b. Permitirá capturar imágenes con el iPhone y subirlas a la aplicación para estimar el BCS de las vacas.

Modelo de almacenamiento de datos



Originalmente se tenía planeado usar Cassandra debido al peso de 150GB del Dataset Chino que se contemplaba utilizar, sin embargo, al solamente utilizar las fotos que se tomaron en el CAETEC y al posteriormente bajar su resolución, no tiene un peso tan grande. De igual manera, en un proyecto donde se podría tener un mayor número de imágenes, lo ideal sería retomar el uso de Cassandra para el almacenamiento de las mismas.

Conjunto de datos

Extracción el conjunto de datos, limpieza y carga a la plataforma seleccionada

78 vacas y un total de 383 imágenes cargadas en Google Drive separadas en carpetas por su ID correspondiente.

Dataset original:
vacas_nuevas

Imágenes procesadas:
procesadas

Scripts de configuración

Se utilizó un script para procesar las imágenes originales, donde lo que hace con cada archivo es:

1. **Filtrar.** Omite los archivos ocultos de macOS (.DS_Store, __MACOSX) y las carpetas excluidas (basurero, vaca extra, vacas fotos, todas). Tampoco toma nada que no sea JPG, PNG o HEIC/HEIF. Todo lo que omite, salvo los archivos ocultos, lo anota en ignorados.csv con el motivo.
2. **Validar la estructura.** Si una foto no está exactamente en originales/ID_vaca/foto, la marca como error.
3. **Asignar identificadores.**
    - imagen_id: un hash SHA-256 de la ruta del archivo.
    - sha256_original: un hash del contenido, que sirve para detectar duplicados.
4. **Procesar la imagen.** Corrige la orientación EXIF, la convierte a RGB y la reduce a un máximo de 1024 px por lado sin deformarla. La guarda como JPEG de calidad 95 con el nombre <imagen_id>.jpg.
5. **Conservar las etiquetas previas.** Si ya existía un inventario.csv, recupera las columnas bcs y conjunto de cada imagen. Así puedes volver a ejecutar el script sin perder etiquetas que ya habían capturado.

Link al script:

https://drive.google.com/file/d/1I3RTBtnNIE2UvSmfQ6Udn5AYK_-Unyd3/view?usp=sharing

Muestra cargada al repositorio de Github

En un notebook de Google Colab se cargaron las imágenes de la carpeta de Google Drive con el dataset original y el procesado, donde se visualizan y comparan 10 de ellas lado a lado:

visualizar_vacas_procesadas.ipynb

Separación de datos

Se hizo la separación en conjuntos de prueba y entrenamiento utilizando el esquema k-fold cross validation en el mismo notebook.
Es importante mencionar que la separación debe ser por vaca, no por foto. Todos los folds tienen el mismo número de vacas. Actualmente se hizo únicamente con las 10 imágenes que se cargaron.

Enfoque del proyecto (Big Data)

Para saber si nos estamos enfrentando a un proyecto de big data, lo que tomamos en consideración son los puntos vistos en clase:

1. **Volumen**
    a. En total si trabajamos con el dataset chino en su totalidad y con las imágenes tomadas por el grupo estaríamos trabajando con aproximadamente 60k imágenes
    b. Igualmente es una cantidad considerable de datos podría no usarse procesamiento distribuido
2. **Velocidad**
    a. Actualmente se piensa que para la primera versión del modelo se procesaron imágenes almacenadas en el dispositivo
    b. Se tiene pensado que para una futura versión, si se sigue trabajando el proyecto, es que haga el procesamiento de la imagen en tiempo real, pero por el momento no va a ser necesario
    c. por estas razones no cumple con este punto de la velocidad
3. **Variedad**
    a. En este caso solo vamos a trabajar con datos estructurados que son las imagénes de las vacas y su respectivo Body Condition Score
    b. Al solo trabajar con solo estos datos no tenemos tanta variedad de tipo de datos o de diferentes fuentes de información
4. **Veracidad**
    a. Existen problemas de calidad, como imágenes sin identificador de vaca.
    b. Los datasets tienen diferentes rangos de BCS.
    c. Hay imágenes repetidas de los mismos animales.
    d. Presenta desafíos importantes de veracidad.

5. **Valor**
    a. Buscamos automatizar la estimación del Body Condition Score (BCS).
    b. Esto puede ayudar a tomar decisiones sobre alimentación, salud y manejo del ganado.